

# ME731 - Métodos em Análise Multivariada

## – Distribuição Normal Multivariada I –

Prof. Carlos Trucíos  
[ctrucios@unicamp.br](mailto:ctrucios@unicamp.br)  
[ctruciosm.github.io](https://github.com/ctruciosm)

Instituto de Matemática, Estatística e Computação Científica,  
Universidade Estadual de Campinas

Aula 04



# Agenda I

- 1 Introdução
- 2 Definição
- 3 Propriedades
- 4 Apêndice

# Introdução

# Introdução

- Várias das técnicas que serão vistas nesta disciplina baseiam-se na suposição de Normalidade Multivariada.
- Em alguns casos, a distribuição Normal Multivariada é uma boa aproximação do fenômeno em estudo.
- O Teorema Central do Limite (TCL) permitirá obter distribuições aproximadas de estatísticas multivariadas.

# Definição

# Definição

## Distribuição Normal Multivariada

Seja  $\mathbf{X} = (X_1, X_2, \dots, X_p)'$  um vetor aleatório  $p$ -dimensional.  $\mathbf{X}$  tem distribuição Normal Multivariada com vetor de medias  $\mu$  e matriz de covariância  $\Sigma > 0$ , denotado por  $\mathbf{X} \sim N_p(\mu, \Sigma)$ , se sua função de densidade é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-(\mathbf{x}-\mu)' \Sigma^{-1} (\mathbf{x}-\mu)/2},$$

com  $-\infty < x_i < \infty, \forall i = 1, \dots, p$ .

# Definição

## Distribuição Normal Multivariada

Seja  $\mathbf{X} = (X_1, X_2, \dots, X_p)'$  um vetor aleatório  $p$ -dimensional.  $\mathbf{X}$  tem distribuição Normal Multivariada com vetor de medias  $\mu$  e matriz de covariância  $\Sigma > 0$ , denotado por  $\mathbf{X} \sim N_p(\mu, \Sigma)$ , se sua função de densidade é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-(\mathbf{x}-\mu)' \Sigma^{-1} (\mathbf{x}-\mu)/2},$$

com  $-\infty < x_i < \infty, \forall i = 1, \dots, p$ .

Para ver uma ilustração do caso bivariado entre aqui. —

# Definição

## Teorema

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$  e seja  $\Sigma^{1/2}$  a matriz raiz quadrada de  $\Sigma$ . Então  $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(0, I)$  e  $Y_1, \dots, Y_p$  são v.a independentes  $\sim N(0, 1)$ .



# Definição

## Teorema

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$  e seja  $\Sigma^{1/2}$  a matriz raiz quadrada de  $\Sigma$ . Então  $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(0, I)$  e  $Y_1, \dots, Y_p$  são v.a independentes  $\sim N(0, 1)$ .

## Demonstração:

- $\mathbf{y} = \Sigma^{-1/2}(\mathbf{x} - \mu) \rightarrow \mathbf{x} = u(\mathbf{y}) = \Sigma^{1/2}\mathbf{y} + \mu.$

# Definição

## Teorema

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$  e seja  $\Sigma^{1/2}$  a matriz raiz quadrada de  $\Sigma$ . Então  $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(0, I)$  e  $Y_1, \dots, Y_p$  são v.a independentes  $\sim N(0, 1)$ .

## Demonstração:

- $\mathbf{y} = \Sigma^{-1/2}(\mathbf{x} - \mu) \rightarrow \mathbf{x} = u(\mathbf{y}) = \Sigma^{1/2}\mathbf{y} + \mu.$
- $\mathbf{J} = \left| \frac{\partial \mathbf{x}}{\partial \mathbf{y}'} \right| = \left| \frac{\partial \Sigma^{1/2}\mathbf{y} + \mu}{\partial \mathbf{y}'} \right| = \left| \Sigma^{1/2} \right| = |\Sigma|^{1/2}$

# Definição

## Teorema

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$  e seja  $\Sigma^{1/2}$  a matriz raiz quadrada de  $\Sigma$ . Então  $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(0, I)$  e  $Y_1, \dots, Y_p$  são v.a independentes  $\sim N(0, 1)$ .

## Demonstração:

- $\mathbf{y} = \Sigma^{-1/2}(\mathbf{x} - \mu) \rightarrow \mathbf{x} = u(\mathbf{y}) = \Sigma^{1/2}\mathbf{y} + \mu.$
- $\mathbf{J} = \left| \frac{\partial \mathbf{x}}{\partial \mathbf{y}'} \right| = \left| \frac{\partial \Sigma^{1/2}\mathbf{y} + \mu}{\partial \mathbf{y}'} \right| = \left| \Sigma^{1/2} \right| = |\Sigma|^{1/2}$
- $(\mathbf{x} - \mu)' \Sigma^{-1}(\mathbf{x} - \mu) = \mathbf{y}'\mathbf{y}$

# Definição

## Teorema

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$  e seja  $\Sigma^{1/2}$  a matriz raiz quadrada de  $\Sigma$ . Então  $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(0, I)$  e  $Y_1, \dots, Y_p$  são v.a independentes  $\sim N(0, 1)$ .

## Demonstração:

- $\mathbf{y} = \Sigma^{-1/2}(\mathbf{x} - \mu) \rightarrow \mathbf{x} = u(\mathbf{y}) = \Sigma^{1/2}\mathbf{y} + \mu.$
- $\mathbf{J} = \left| \frac{\partial \mathbf{x}}{\partial \mathbf{y}'} \right| = \left| \frac{\partial \Sigma^{1/2}\mathbf{y} + \mu}{\partial \mathbf{y}'} \right| = \left| \Sigma^{1/2} \right| = |\Sigma|^{1/2}$
- $(\mathbf{x} - \mu)' \Sigma^{-1}(\mathbf{x} - \mu) = \mathbf{y}'\mathbf{y}$
- $f_{\mathbf{Y}}(\mathbf{y}) = |\mathbf{J}| f_{\mathbf{X}}(u(\mathbf{y})) = |\Sigma|^{1/2} \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\mathbf{y}'\mathbf{y}/2} = \frac{1}{(2\pi)^{p/2}} e^{-\mathbf{y}'\mathbf{y}/2}.$

# Definição

## Demonstração:

Para provar que  $Y_1, \dots, Y_p$  são  $N(0, 1)$  independentes, basta reescrever a densidade da normal multivariada.

# Definição

## Demonstração:

Para provar que  $Y_1, \dots, Y_p$  são  $N(0, 1)$  independentes, basta reescrever a densidade da normal multivariada.

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\mathbf{y}'\mathbf{y}/2} = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2}$$

# Definição

## Demonstração:

Para provar que  $Y_1, \dots, Y_p$  são  $N(0, 1)$  independentes, basta reescrever a densidade da normal multivariada.

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\mathbf{y}'\mathbf{y}/2} = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2}$$
$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2} = \prod_{i=1}^p \underbrace{\frac{1}{(2\pi)^{1/2}} e^{-y_i^2/2}}_{N(0,1)}$$

# Definição

## Demonstração:

Para provar que  $Y_1, \dots, Y_p$  são  $N(0, 1)$  independentes, basta reescrever a densidade da normal multivariada.

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\mathbf{y}'\mathbf{y}/2} = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2}$$
$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2} = \prod_{i=1}^p \underbrace{\frac{1}{(2\pi)^{1/2}} e^{-y_i^2/2}}_{N(0,1)}$$

Logo, pelo Teorema da fatoração,  $Y_1, \dots, Y_p$  são  $N(0, 1)$  independentes.



# Propriedades

# Propriedades

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$ .

- ① A distribuição é simétrica em torno de  $\mu$ .
- ② A distribuição tem um único máximo em  $\mu$ .
- ③  $U = (\mathbf{X} - \mu)' \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$ .
- ④  $\varphi_{\mathbf{X}}(t) = e^{it'\mu - \frac{1}{2}t'\Sigma t}$ .
- ⑤  $\mathbb{E}(\mathbf{X}) = \mu$  e  $\mathbb{V}(\mathbf{X}) = \Sigma$ .
- ⑥  $\mathbf{Y} = A_{q \times p} \mathbf{X} + c_{q \times 1} \sim N_q(A\mu + c, A\Sigma A')$
- ⑦ Qualquer combinação linear dos elementos de  $\mathbf{X}$  tem distribuição normal univariada.
- ⑧ Qualquer subconjunto de  $\mathbf{X}$  tem distribuição Normal (multivariada).

# Propriedades

Seja  $\mathbf{X} \sim N_p(\mu, \Sigma)$ .

- ① A distribuição é simétrica em torno de  $\mu$ .
- ② A distribuição tem um único máximo em  $\mu$ .
- ③  $U = (\mathbf{X} - \mu)' \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$ .
- ④  $\varphi_{\mathbf{X}}(t) = e^{it'\mu - \frac{1}{2}t'\Sigma t}$ .
- ⑤  $\mathbb{E}(\mathbf{X}) = \mu$  e  $\mathbb{V}(\mathbf{X}) = \Sigma$ .
- ⑥  $\mathbf{Y} = A_{q \times p} \mathbf{X} + c_{q \times 1} \sim N_q(A\mu + c, A\Sigma A')$
- ⑦ Qualquer combinação linear dos elementos de  $\mathbf{X}$  tem distribuição normal univariada.
- ⑧ Qualquer subconjunto de  $\mathbf{X}$  tem distribuição Normal (multivariada).

**Demonstração:**

# Propriedades

**Marginais Normais implicam em Normalidade Multivariada?**

# Propriedades

**Marginais Normais implicam em Normalidade Multivariada? Não!**

# Propriedades

**Marginais Normais implicam em Normalidade Multivariada? Não!**

Seja  $(X, Y)$  um vetor aleatório com densidade

$$f(x, y) = \phi(x)\phi(y) + h(x)h(y), \quad (x, y) \in \mathbb{R}^2$$

em que  $\phi(z) = \frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$  e  $h(z) = (2\pi e)^{-1/2} z^3 I_{[-1,1]}(z)$

# Propriedades

## Marginais Normais implicam em Normalidade Multivariada? **Não!**

Seja  $(X, Y)$  um vetor aleatório com densidade

$$f(x, y) = \phi(x)\phi(y) + h(x)h(y), \quad (x, y) \in \mathbb{R}^2$$

em que  $\phi(z) = \frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$  e  $h(z) = (2\pi e)^{-1/2} z^3 I_{[-1,1]}(z)$

- $f(x, y)$  é de fato densidade ( $f(x, y) \geq 0$  e  $\int \int f(x, y) = 1$ ) conjunta mas não é Normal Bivariada.
- $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \phi(x)$  e  $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \phi(y)$

O vetor aleatório  $(X, Y)$  com densidade  $f(x, y)$  tem marginais  $N(0, 1)$  mas não tem distribuição normal bivariada.

# Propriedades

## Marginais Normais implicam em Normalidade Multivariada? **Não!**

Seja  $(X, Y)$  um vetor aleatório com densidade

$$f(x, y) = \phi(x)\phi(y) + h(x)h(y), \quad (x, y) \in \mathbb{R}^2$$

em que  $\phi(z) = \frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$  e  $h(z) = (2\pi e)^{-1/2} z^3 I_{[-1,1]}(z)$

- $f(x, y)$  é de fato densidade ( $f(x, y) \geq 0$  e  $\int \int f(x, y) = 1$ ) conjunta mas não é Normal Bivariada.
- $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \phi(x)$  e  $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \phi(y)$

O vetor aleatório  $(X, Y)$  com densidade  $f(x, y)$  tem marginais  $N(0, 1)$  mas não tem distribuição normal bivariada.

Para mais exemplos ver o capítulo 10 de Stoyanov (2013).



# Distribuição condicional

## Distribuição condicional

Seja  $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)' \in \mathbb{R}^p$  com  $\mathbf{X}_1 \in \mathbb{R}^k$  e  $\mathbf{X}_2 \in \mathbb{R}^{p-k}$  então

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}),$$

em que  $\mu = (\mu_1, \mu_2)'$  e

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \quad \text{e} \quad |\Sigma_{22}| > 0.$$

# Distribuição condicional: Demonstração

Por definição

$$f_{\mathbf{x}_1|\mathbf{x}_2=\mathbf{x}_2} = \frac{f_{\mathbf{x}}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{x}_2}(\mathbf{x}_2)} = \frac{|\Sigma|^{-1/2} (2\pi)^{-p/2} e^{-\frac{1}{2}(\mathbf{x}-\mu)' \Sigma^{-1}(\mathbf{x}-\mu)}}{|\Sigma_{22}|^{-1/2} (2\pi)^{-(p-k)/2} e^{-\frac{1}{2}(\mathbf{x}_2-\mu_2)' \Sigma_{22}^{-1}(\mathbf{x}_2-\mu_2)}}$$

# Distribuição condicional: Demonstração

Por definição

$$f_{\mathbf{x}_1|\mathbf{x}_2=\mathbf{x}_2} = \frac{f_{\mathbf{x}}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{x}_2}(\mathbf{x}_2)} = \frac{|\Sigma|^{-1/2} (2\pi)^{-p/2} e^{-\frac{1}{2}(\mathbf{x}-\mu)'\Sigma^{-1}(\mathbf{x}-\mu)}}{|\Sigma_{22}|^{-1/2} (2\pi)^{-(p-k)/2} e^{-\frac{1}{2}(\mathbf{x}_2-\mu_2)'\Sigma_{22}^{-1}(\mathbf{x}_2-\mu_2)}}$$

Por propriedade de determinantes

$$|\Sigma|^{-1/2} = |\Sigma_{22}|^{-1/2} |\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}|^{-1/2}$$

# Distribuição condicional: Demonstração

Por definição

$$f_{\mathbf{x}_1|\mathbf{x}_2=\mathbf{x}_2} = \frac{f_{\mathbf{x}}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{x}_2}(\mathbf{x}_2)} = \frac{|\Sigma|^{-1/2} (2\pi)^{-p/2} e^{-\frac{1}{2}(\mathbf{x}-\mu)' \Sigma^{-1}(\mathbf{x}-\mu)}}{|\Sigma_{22}|^{-1/2} (2\pi)^{-(p-k)/2} e^{-\frac{1}{2}(\mathbf{x}_2-\mu_2)' \Sigma_{22}^{-1}(\mathbf{x}_2-\mu_2)}}$$

Por propriedade de determinantes

$$|\Sigma|^{-1/2} = |\Sigma_{22}|^{-1/2} |\Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}|^{-1/2}$$

Assim,

$$\frac{|\Sigma|^{-1/2} (2\pi)^{-p/2}}{|\Sigma_{22}|^{-1/2} (2\pi)^{-(p-k)/2}} = |\Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}|^{-1/2} (2\pi)^{-k/2}$$

# Distribuição condicional: Demonstração

Por outro lado, precisamos calcular

$$e^{-\frac{1}{2}[(\mathbf{x}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})-(\mathbf{x}_2-\boldsymbol{\mu}_2)'\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2-\boldsymbol{\mu}_2)]}$$

# Distribuição condicional: Demonstração

Por outro lado, precisamos calcular

$$e^{-\frac{1}{2}[(\mathbf{x}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})-(\mathbf{x}_2-\boldsymbol{\mu}_2)'\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2-\boldsymbol{\mu}_2)]}$$

Seja  $C_{11} = (\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21})^{-1}$ , então  $(\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) =$

# Distribuição condicional: Demonstração

Por outro lado, precisamos calcular

$$e^{-\frac{1}{2}[(\mathbf{x}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})-(\mathbf{x}_2-\boldsymbol{\mu}_2)'\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2-\boldsymbol{\mu}_2)]}$$

Seja  $C_{11} = (\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21})^{-1}$ , então  $(\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) =$

$$\begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix}' \begin{pmatrix} C_{11} & -C_{11}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1} \\ -\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}C_{11} & \boldsymbol{\Sigma}_{22}^{-1} + \boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}C_{11}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix} =$$

# Distribuição condicional: Demonstração

Por outro lado, precisamos calcular

$$e^{-\frac{1}{2}[(\mathbf{x}-\mu)' \Sigma^{-1}(\mathbf{x}-\mu) - (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]}$$

Seja  $C_{11} = (\Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21})^{-1}$ , então  $(\mathbf{x} - \mu)' \Sigma^{-1}(\mathbf{x} - \mu) =$

$$\begin{pmatrix} \mathbf{x}_1 - \mu_1 \\ \mathbf{x}_2 - \mu_2 \end{pmatrix}' \begin{pmatrix} C_{11} & -C_{11} \Sigma_{12} \Sigma_{22}^{-1} \\ -\Sigma_{22}^{-1} \Sigma_{21} C_{11} & \Sigma_{22}^{-1} + \Sigma_{22}^{-1} \Sigma_{21} C_{11} \Sigma_{12} \Sigma_{22}^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{x}_1 - \mu_1 \\ \mathbf{x}_2 - \mu_2 \end{pmatrix} =$$

$$\begin{aligned} & (\mathbf{x}_1 - \mu_1)' C_{11} (\mathbf{x}_1 - \mu_1) - (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} \Sigma_{21} C_{11} (\mathbf{x}_1 - \mu_1) - \\ & (\mathbf{x}_1 - \mu_1)' C_{11} \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) + (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) + \\ & (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} \Sigma_{21} C_{11} \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \end{aligned}$$



# Distribuição condicional: Demonstração

Por outro lado, precisamos calcular

$$e^{-\frac{1}{2}[(\mathbf{x}-\mu)' \Sigma^{-1}(\mathbf{x}-\mu) - (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]}$$

Seja  $C_{11} = (\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})^{-1}$ , então  $(\mathbf{x} - \mu)' \Sigma^{-1}(\mathbf{x} - \mu) =$

$$\begin{pmatrix} \mathbf{x}_1 - \mu_1 \\ \mathbf{x}_2 - \mu_2 \end{pmatrix}' \begin{pmatrix} C_{11} & -C_{11}\Sigma_{12}\Sigma_{22}^{-1} \\ -\Sigma_{22}^{-1}\Sigma_{21}C_{11} & \Sigma_{22}^{-1} + \Sigma_{22}^{-1}\Sigma_{21}C_{11}\Sigma_{12}\Sigma_{22}^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{x}_1 - \mu_1 \\ \mathbf{x}_2 - \mu_2 \end{pmatrix} =$$

$$\begin{aligned} & (\mathbf{x}_1 - \mu_1)' C_{11}(\mathbf{x}_1 - \mu_1) - (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} \Sigma_{21} C_{11} (\mathbf{x}_1 - \mu_1) - \\ & (\mathbf{x}_1 - \mu_1)' C_{11} \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) + (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) + \\ & (\mathbf{x}_2 - \mu_2)' \Sigma_{22}^{-1} \Sigma_{21} C_{11} \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \end{aligned}$$

$$= [(\mathbf{x}_1 - \mu_1) - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]' C_{11} [(\mathbf{x}_1 - \mu_1) - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]$$

# Distribuição condicional: Demonstração

$$\text{Então, } f_{\mathbf{x}_1|\mathbf{x}_2=\mathbf{x}_2}(\mathbf{x}_1, \mathbf{x}_2) = \frac{1}{(2\pi)^{k/2} |\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}|^{1/2}} e^{-\frac{1}{2}[(\mathbf{x}_1 - \mu_1) - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]' C_{11}[(\mathbf{x}_1 - \mu_1) - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]}$$

que é a densidade de uma  $N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$

# Apêndice

# Apêndice

## Decomposição espectral

Toda matriz simétrica  $A_{p \times p}$  pode ser escrita como

$$A = P\Lambda P' = \sum_{i=1}^p \lambda_i \mathbf{e}_i \mathbf{e}_i',$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

com  $\lambda_1, \dots, \lambda_p$  sendo os autovalores e

$$P = (\mathbf{e}_1, \dots, \mathbf{e}_p)$$

é uma matriz ortonormal com os autovetores (associados os seus respectivos autovalores) de  $A$ .

# Apêndice

## Matrizes particionadas

Sejam  $\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix}$ ,  $A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}$  e  $B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}$  então:

- $\mathbf{X}' = (\mathbf{X}'_1, \mathbf{X}'_2)$
- $\mathbf{X}'A = [\mathbf{X}'_1A_{11} + \mathbf{X}'_2A_{21} \quad \mathbf{X}'_1A_{12} + \mathbf{X}'_2A_{22}]$
- $\mathbf{X}'A\mathbf{X} = \mathbf{X}'_1A_{11}\mathbf{X}_1 + \mathbf{X}'_2A_{21}\mathbf{X}_1 + \mathbf{X}'_1A_{12}\mathbf{X}_2 + \mathbf{X}'_2A_{22}\mathbf{X}_2$
- $AB = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix}$
- Se A for simétrica e quadrada  $|A| = |A_{22}||A_{11} - A_{12}A_{22}^{-1}A_{21}|$

# Apêndice

## Matrizes particionadas

Se  $A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}$  for simétrica e quadrada,

$$A^{-1} = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix},$$

com

- $C_{11} = (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1}$ ,
- $C_{12} = -C_{11}A_{12}A_{22}^{-1}$ ,
- $C_{21} = -A_{22}^{-1}A_{21}C_{11}$  e
- $C_{22} = A_{22}^{-1} + A_{22}^{-1}A_{21}C_{11}A_{12}A_{22}^{-1}$

# Apêndice

## Matriz raiz quadrada

Seja  $A_{k \times k} > 0$  com decomposição espectral. A matriz raiz quadrada de  $A$ , denotada por  $A^{1/2}$  é dada por

$$A^{1/2} = \sum_{i=1}^k \sqrt{\lambda_i} \mathbf{e}_i \mathbf{e}_i' = P \Lambda^{1/2} P'.$$

**Observação:**  $A^{1/2} A^{1/2} = A$  e  $A^{1/2} A^{-1/2} = I$ .

# Apêndice

## Matriz raiz quadrada

Seja  $A_{k \times k} > 0$  com decomposição espectral. A matriz raiz quadrada de  $A$ , denotada por  $A^{1/2}$  é dada por

$$A^{1/2} = \sum_{i=1}^k \sqrt{\lambda_i} \mathbf{e}_i \mathbf{e}_i' = P \Lambda^{1/2} P'.$$

**Observação:**  $A^{1/2} A^{1/2} = A$  e  $A^{1/2} A^{-1/2} = I$ .

De fato, podemos definir qualquer potência da matriz  $A$  como

$$A^\alpha = P \Lambda^\alpha P'.$$



# Apêndice

## Distâncias

Sejam  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ . A distância  $d : \mathbb{R}^{2p} \rightarrow \mathbb{R}_+$  tal que:

- $d(\mathbf{x}, \mathbf{y}) > 0$ ,  $\forall \mathbf{x} \neq \mathbf{y}$
- $d(\mathbf{x}, \mathbf{y}) = 0$ , sss  $\mathbf{x} = \mathbf{y}$
- $d(\mathbf{x}, \mathbf{y}) \leq d(\mathbf{x}, \mathbf{z}) + d(\mathbf{y}, \mathbf{z})$ ,  $\forall \mathbf{x}, \mathbf{y}, \mathbf{z}$ .

A distância Euclidiana entre dois pontos  $\mathbf{x}$  e  $\mathbf{y}$  é definida como

$$d^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})' \mathbf{I} (\mathbf{x} - \mathbf{y})$$

A distância de Mahalanobis entre dois pontos  $\mathbf{x}$  e  $\mathbf{y}$  é definida como

$$d^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})' \Sigma^{-1} (\mathbf{x} - \mathbf{y}),$$

em que  $\Sigma$  é a matriz comum de covariância.

# Apêndice

## Teorema de Sklar

Seja  $F$  uma função distribuição  $p$ -dimensional com marginais  $F_{X_1}, \dots, F_{X_p}$ . Então, existe uma cópula  $p$ -dimensional  $C$ , tal que  $\forall \mathbf{x} \in \mathbb{R}^p$ :

$$F(x_1, \dots, x_p) = C\{F_{X_1}(x_1), \dots, F_{X_p}(x_p)\}. \quad (1)$$

Se  $F_{X_1}, \dots, F_{X_p}$  são todas contínuas, então  $C$  é única.

Por outro lado, se  $C$  é uma cópula e  $F_{X_1}, \dots, F_{X_p}$  são funções distribuição, então  $F$  definida por (1) é uma função distribuição  $p$ -dimensional com marginais  $F_{X_1}, \dots, F_{X_p}$ .

# Referências

## Referências

- Härdle, W. K., & Simar, L. (2019). Applied Multivariate Statistical Analysis. Fifth Edition. Springer Nature. Capítulo 4.
- Johnson, R. A., & Wichern, D. W. (2007). Applied multivariate statistical analysis. Sixth Edition. Pearson Prentice Hall. Capítulo 4.
- Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). Multivariate Analysis. Academic Press. Capítulo 2.
- Stoyanov, J. M. (2013). Counterexamples in Probability. Third Edition. Dover. Capítulo 10.